



PUC

MVP

Curso - Engenharia de Dados

Alexia FERREIRA

Alexia.ferreirac@gmail.com

CONTENTS

Solução escolhida	2
Objetivo	3
Base dados	4
Etapa Bronze — Upload dos arquivos pelo Databricks	4
Etapa Silver – Transformação dos dados	6
1. Verificação das Datas	7
2. Produto inconsistente detectado.....	7
3. Clientes recorrentes — padrão do campo	8
4.Limpeza e adequação	9
Etapa Gold - Tabelas Analíticas de Vendas de Café	11
Modelagem e demosntrativo	12

SOLUÇÃO ESCOLHIDA

Durante os estudos relacionados às plataformas de dados e processamento analítico em nuvem, foi escolhida a ferramenta **Databricks** para o desenvolvimento deste projeto. O Databricks é uma plataforma unificada de dados e inteligência artificial que permite a ingestão, transformação, armazenamento, governança e análise de grandes volumes de dados em um único ambiente colaborativo.

A escolha do Databricks se deve à sua ampla adoção no mercado, arquitetura escalável baseada em Apache Spark e suporte nativo a práticas modernas de Engenharia de Dados, como Data Lakehouse, processamento distribuído, pipelines ETL/ELT e governança de dados. Além disso, a plataforma possibilita a implementação da arquitetura Medallion (Bronze, Silver e Gold), facilitando a organização dos dados desde sua forma bruta até camadas analíticas prontas para consumo.

A solução proposta pelo Databricks contempla:

- **Unificação de Dados:** integração de dados provenientes de diferentes fontes em um ambiente centralizado, permitindo a criação de uma visão única e consistente das informações;
- **Arquitetura Lakehouse:** combinação dos benefícios dos Data Lakes e Data Warehouses, possibilitando análises tanto em dados brutos quanto em dados estruturados e refinados;
- **Eficiência Operacional:** automação de processos de ingestão, transformação e monitoramento dos dados, reduzindo esforços operacionais e aumentando a confiabilidade das informações;
- **Análise e Inteligência de Negócios:** disponibilização de dados tratados e modelados para geração de dashboards, relatórios e análises que apoiam a tomada de decisão;
- **Governança de Dados:** utilização do **Unity Catalog** para centralizar o gerenciamento de metadados, controle de acesso, documentação das tabelas, rastreabilidade e linhagem dos dados;
- **Escalabilidade e Performance:** capacidade de processar grandes volumes de dados de forma distribuída, atendendo desde análises exploratórias até cargas de produção;
- **Segurança e Conformidade:** aplicação de mecanismos de controle de acesso, auditoria e governança que garantem a proteção e o uso adequado dos dados.

Dessa forma, o Databricks oferece uma plataforma completa para construção do pipeline de dados da cafeteria, abrangendo desde a ingestão dos dados transacionais até a disponibilização de informações consolidadas para análises de vendas, comportamento dos clientes e desempenho do negócio.

OBJETIVO

O presente projeto tem como objetivo desenvolver uma solução de Engenharia de Dados utilizando o **Databricks** e a arquitetura **Medallion (Bronze, Silver e Gold)** para consolidar, tratar e disponibilizar dados de vendas de uma cafeteria, transformando dados brutos em informações analíticas capazes de apoiar a tomada de decisão do negócio. A solução contempla a ingestão, transformação, modelagem e governança dos dados por meio do **Unity Catalog**, garantindo qualidade, rastreabilidade e acessibilidade das informações.

A necessidade de negócio identificada consiste em:

Entender quais fatores influenciam as vendas, a receita e o comportamento dos clientes da cafeteria para apoiar decisões operacionais e comerciais

Para atender esse objetivo, o projeto busca responder às seguintes perguntas estratégicas:

- Quais são os produtos mais vendidos e quais geram maior faturamento?
- Quais horários apresentam maior volume de vendas e receita?
- Quais dias da semana são mais lucrativos?
- Qual é o ticket médio dos clientes e como ele evolui ao longo do tempo?
- Qual a forma de pagamento mais utilizada pelos consumidores?
- Quem são os clientes mais frequentes e qual sua contribuição para a receita?
- Qual o comportamento dos clientes recorrentes e seu padrão de consumo?

Como resultado, serão disponibilizadas tabelas analíticas e indicadores de negócio que permitam monitorar o desempenho da cafeteria, identificar oportunidades de otimização de estoque, apoiar estratégias comerciais, compreender hábitos de consumo e fortalecer ações voltadas à fidelização de clientes. Entre as análises geradas destacam-se faturamento diário, vendas por produto, ticket médio, clientes recorrentes, vendas por horário e receita por forma de pagamento.

Dessa forma, o projeto demonstra a aplicação prática dos conceitos de Engenharia de Dados em uma plataforma moderna de dados, utilizando o **Databricks** para construir um pipeline completo, escalável e orientado a negócio.

BASE DADOS

A base de dados escolhida foi a Coffe Sales disponibilizada no Kaggle, a qual possui dois arquivos CVS.

Link para acessar o ambiente de download da base de dados [Coffee Sales](#).

A coleta da base dados deu-se por download do arquivo zip.

ETAPA BRONZE — UPLOAD DOS ARQUIVOS PELO DATABRICKS

Após realizado o download da base zipada da dados foram extraídos dois arquivos.

Os arquivos index_1.csv e index_2.csv contêm registros de vendas de uma **máquina de café**, com pequenas diferenças de schema entre si. O pipeline ETL unificará as duas fontes na camada Bronze.

1. No menu lateral, selecionado **New → Add or upload data**
2. Selecionado **Upload files to a volume**
3. Upload realizado dos arquivos index_1.csv e index_2.csv, criando schema **bronze** e unificando os arquivos em 1 tabela **transaction.raw**




Figura 1 – Criação da tabela **transaction_raw** para armazenamento dos dados na camada Bronze

A tabela contém dados brutos de transações relacionadas à compra de café. Ela inclui detalhes como a data e hora da transação, o tipo de dinheiro utilizado, o valor gasto, o nome do café adquirido e o método de pagamento.

Diferença entre os arquivos: index_2.csv não possui a coluna card. Na Bronze, ela será preenchida com NULL para manter o schema unificado.

Coluna	Tipo	Descrição	index_1	index_2
date	DATE	Data da venda	✓	✓
datetime	TIMESTAMP	Data e hora exatas	✓	✓
cash_type	STRING	Tipo de pagamento (card/cash)	✓	✓
card	STRING	Número/identificador do cartão	✓	✗
money	FLOAT	Valor pago	✓	✓
coffee_name	STRING	Nome do café vendido	✓	✓

Tabela 1 – Descrição dos tipo de dados na tabela **transaction_raw**




Figura 2 – Verificação das colunas existentes na tabela **transactions.raw**

ETAPA SILVER – TRANSFORMAÇÃO DOS DADOS

Para início da etapa silver, foi necessário a criação de um novo schema que leva o nome da etapa, para assim, seguir posteriormente com a transformação dos dados.

1. No menu lateral foi selecionado a opção SQL Editor;
2. Seleciona o SQL Warehouse ativo
3. Criado o Schema **silver**




Figura 3 – Criação do schema Silver


Logo após foi realizado a criação da tabela **coffee.sales.clean** e a verificação dos dados para checagem de inconsistências. Realizado 3 queries de análise exploratória da Bronze:

#	Objetivo	Técnica SQL
1	Verificar tipos e formatos de data	SELECT ... LIMIT com amostra
2	Detectar inconsistências nos produtos	GROUP BY + ORDER BY alfabético
3	Identificar clientes recorrentes	GROUP BY card + COUNT + MIN/MAX

Figura 4 – Análise exploratória

1. VERIFICAÇÃO DAS DATAS

Executado uma amostra dos dados verificando os tipos e formatos das colunas date e datetime. O resultado mostrou date como tipo **DATE** (2024-03-01) e datetime como **TIMESTAMP** (2024-03-01T10:15:50.520Z) — já no formato correto, sem necessidade de conversão.



	date	datetime	coffee_name	cash_type	card
1	2024-03-01	2024-03-01T10:15:50.520+00:00	Latte	CARD	ANON-0000-0000
2	2024-03-01	2024-03-01T12:19:22.539+00:00	Hot Chocolate	CARD	ANON-0000-0000
3	2024-03-01	2024-03-01T12:20:18.089+00:00	Hot Chocolate	CARD	ANON-0000-0000
4	2024-03-01	2024-03-01T13:46:33.006+00:00	Americano	CARD	ANON-0000-0000
5	2024-03-01	2024-03-01T13:48:14.626+00:00	Latte	CARD	ANON-0000-0000
6	2024-03-01	2024-03-01T15:39:47.726+00:00	Americano with Milk	CARD	ANON-0000-0000
7	2024-03-01	2024-03-01T16:19:02.756+00:00	Hot Chocolate	CARD	ANON-0000-0000
8	2024-03-01	2024-03-01T18:39:03.580+00:00	Americano with Milk	CARD	ANON-0000-0000

Figura 5 – Verificação de data

2. PRODUTO INCONSISTENTE DETECTADO

Listado todos os nomes de produtos distintos com suas contagens, ordenados alfabeticamente para facilitar a identificação visual de duplicatas. O resultado mostrou "Americano with Milk" (824 registros) e "Americano with milk" (44 registros) lado a lado na listagem — mesmo produto com capitalização diferente na letra "m" de "milk".




Figura 6 – Identificação de inconsistências

3. CLIENTES RECORRENTES — PADRÃO DO CAMPO

O item foi agrupado por card calculando total de compras, dias distintos, valor gasto e datas de primeira/última compra — ordenando pelos mais frequentes. O resultado revelou:

- Padrão do campo: ANON-0000-0000-XXXX (dados anonimizados)
- Pagamentos em dinheiro (cash) têm card = NULL — confirmado pela ausência nos resultados
- **Top cliente:** ANON-0000-0000-0012 com **129 compras** em **76 dias distintos**, gastando **R\$ 3.785,92** desde março/2024




Figura 7 – Identificação de padrão de cliente

4. LIMPEZA E ADEQUAÇÃO

Após a checagem dos dados da camada **Bronze** para a camada **Silver**, foram realizadas etapas de limpeza, padronização e enriquecimento da base de vendas da cafeteria. Os registros duplicados e inválidos foram removidos, os campos foram normalizados e os nomes dos produtos padronizados. Também foram criadas dimensões temporais, como hora, dia, mês, período do dia e tipo de dia (útil ou fim de semana), permitindo análises mais detalhadas do comportamento de consumo. Além disso, foram gerados indicadores de recorrência dos clientes, incluindo quantidade de compras, valor total gasto e segmentação em categorias como **VIP**, **Recorrente**, **Ocasional** e **Único**. Como resultado, foi criada uma tabela analítica consolidada e enriquecida, preparada para apoiar análises de vendas, perfil de clientes e tomada de decisão do negócio.




Figura 8 – Adequação dos componentes




Figura 9 – Criação de novas colunas




Figura 10 – Criação das novas categorias VIP, Recorrente, Ocasional e Único

Transformação	O que foi feito
Tratamento das datas	Garante tipos DATE/TIMESTAMP corretos
Padronização dos produtos	Unifica "Americano with milk" → "Americano with Milk" e todos os demais via INITCAP
Dimensão de tempo	Cria hora, dia, mes, ano, nome_dia_semana, nome_mes, ano_mes, periodo_dia (Manhã/Tarde/Noite), tipo_dia (Útil/Fim de Semana)

Clientes Recorrentes	Classifica cada cartão em VIP (≥ 50 compras), Recorrente (10–49), Ocasional (2–9) ou Único (1)
-----------------------------	--

Tabela 2 – Tratamento dos dados

ETAPA GOLD - TABELAS ANALÍTICAS DE VENDAS DE CAFÉ

Com a base de dados devidamente estruturada seguiremos agora com aprimoramento das informações e criação de novas tabelas para uma melhor análise dos dados. A modelagem segue o schema estrela, onde o foco são as vendas, e traz as demais informações das suas dimensões (tipo de bebida, horários, etc) para melhor entendimento do todo.

1. Criação do schema **Gold**;
2. Criação e validação das tabelas: **Faturamento diário, Vendas por produto, Ticket médio, Clientes recorrentes, Vendas por hora, Receita por forma de pagamento.**




Figura 11 – Criação schema Gold




Figura 12 – Criação de novas tabelas para análise

MODELAGEM E DEMOSNTRATIVO

As tabelas possuem as seguintes informações:

Tabela	Grain	Métricas
faturamento_diario	1 linha por dia	receita, vendas, ticket médio, maior/menor venda
vendas_por_produto	1 linha por produto	receita, volume, % do total
ticket_medio	Por mês + período + tipo dia	ticket médio, mínimo, máximo, mediana
cliente_recorrentes	1 linha por cartão	segmento, total gasto, frequência, produto favorito
vendas_por_hora	1 linha por hora	receita, volume, produto mais vendido
receita_por_pagamento	Por forma + mês	receita, ticket médio, % do mês

Tabela 3 – Descrição das tabelas

1. Faturamento por Mês

Fevereiro/2025 teve o maior faturamento (R\$ 16.779), seguido de outubro/2024 (R\$ 13.891). Julho/2024 e janeiro/2025 foram os meses mais fracos.

Faturamento Mensal




Figura 13 – Demonstrativo de vendas mensal

2. Vendas por Produto

Latte lidera com R\$ 28.658, seguido de Americano with Milk (R\$ 26.319, já com a padronização de nome corrigida) e Cappuccino (R\$ 18.514).

Vendas por Produto – Top 10




Figura 14 – Demonstrativo de venda por produto

3. Ticket Médio

O ticket médio caiu de **R\$ 34,62** (mar/2024) para **R\$ 29,52** (mar/2025) — uma tendência de queda ao longo do ano, possivelmente ligada à mudança no mix de produtos vendidos.

Ticket Médio Mensal




Figura 15 – Demonstrativo ticket médio mensal

4. Clientes Recorrentes

Apenas 52 clientes (VIP + Recorrente, 4% da base) geram R\$ 40.519 — cerca de 33% da receita total, evidenciando forte concentração de valor em poucos clientes fiéis.

7 clientes VIP R\$ 16.594 em receita (78,7 compras/cliente em média)	45 Recorrentes R\$ 23.925 em receita (16,9 compras/cliente)	771 clientes Únicos R\$ 24.497 em receita (1 compra cada)
---	--	--

Figura 16 – Demonstrativo Clientes

Segmentação de Clientes




Figura 17 – Demonstrativo Cliente

5.Vendas por Hora

O pico de vendas ocorre às 10h (362 vendas), com segundo pico às 16h (307 vendas) — padrão típico de consumo de café pela manhã e no meio da tarde.

Vendas por Hora do Dia




Figura 18 – Demonstrativo venda/HR

6. Receita por Forma de Pagamento

O pagamento por cartão domina com 95,8% da receita (R\$ 117.114), contra apenas 4,2% em dinheiro (R\$ 5.157).

Receita por Forma de Pagamento




Figura 19 – Demonstrativo pagamento